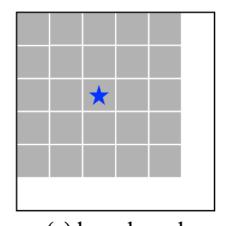
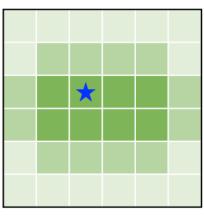
Conformer: Convolutionaugmented Transformer for Speech Recognition

CNN vs Transformer(MHSA)

CNN



(c) large kernel
Attention



(a) global attention

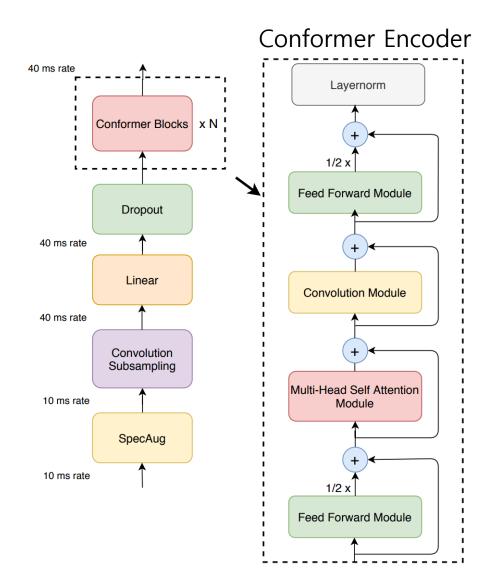
Speech 영역에서 Transformer model은 다른 도메인과 마찬가지로 Long range dependency와 training efficiency로 성공을 거뒀다.

CNN역시 **local context**를 점진적으로 capture하기 때문에 ASR에서 성공을 거뒀다.

그러나 위의 두 모델은 각각의 단점이 있다.

Transformer는 long range global context extraction에 좋지만, fine grained local feature patterns extraction에는 성능이 좋지 않다.

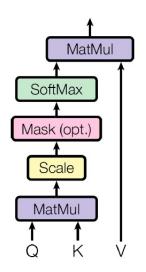
CNN은 local information extraction 성능이 좋고, kernel을 사용하기 때문에 translation equivariance를 유지하며 edge나 shape을 뽑아낼 수 있지만, global information을 capture하기 위해서는 더 깊은 Layer나 parameter가 필요해진다.

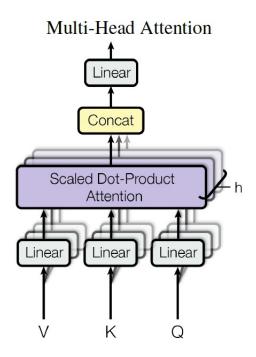


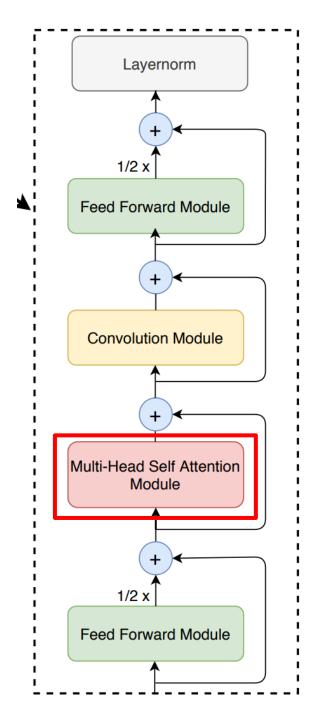
- CNN과 Transformer는 결국 각각의 문제를 가지고 있다.
- 우리는 global contex와 local context의 상호작용이 parameter efficient를 위해 중요할 것이라는 가설을 세웠다.
- 그래서 이것을 해결하기 위해 CNN과 selfattention을 섞어버렸다.

1. Multi-Head Self-Attention Module

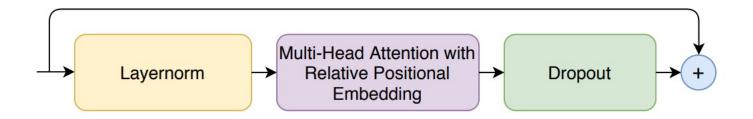
Scaled Dot-Product Attention







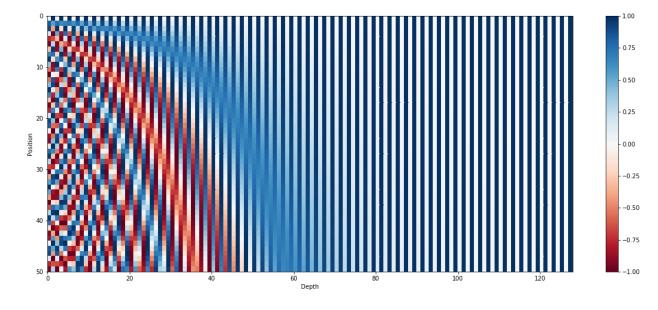
1. Multi-Head Self-Attention Module



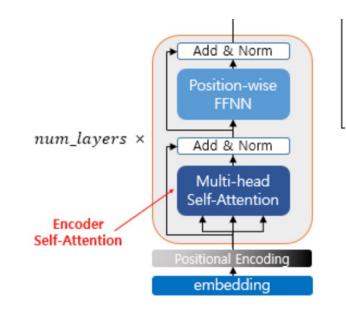
연산 전에 norm을 사용하는 pre-norm을 이용했고, relative positional encoding을 통해서 length가 다른 Input에도 general하게 작용할 수 있게 했다.

1-1. 기존 Positional Encoding

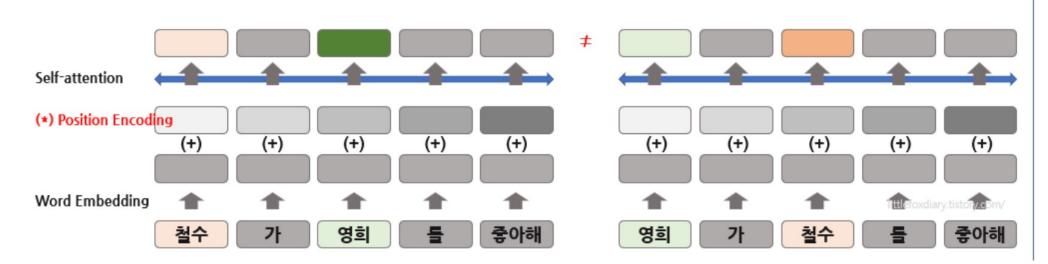
$$egin{aligned} \overrightarrow{p_t}^{(i)} &= f(t)^{(i)} := egin{cases} \sin(\omega_k.t), & ext{if } i = 2k \ \cos(\omega_k.t), & ext{if } i = 2k+1 \end{cases} \ \omega_k &= rac{1}{10000^{2k/d}} \end{aligned}$$



1-1. 기존 Positional Encoding



(b) 위치 인코딩을 더해줌으로써 단어 시퀀스 정보를 줄 수 있고, 아래의 두 문장은 다른 representation을 가짐



1-2. Relative Positional Encoding

인풋 시퀀스 512인 문장에 대해 Self-attention 상황을 가정하면, relative position은 다음과 같이 구할 수 있다.

```
첫 번째 토큰을 기준으로 마지막 토큰은 511만큼 뒤에 있음
tensor([[
                                                   508,
                                                         509,
                                                               510, 511],
                                             507,
                                   3, ...,
                                             506,
                                                   507,
                                                         508,
                                                               509,
                                                                     510],
                                   2, ...,
                                             505,
                                                   506,
                                                         507,
                                                               508,
                                                                     509],
                                   1, ...,
          -3,
                                             504,
                                                   505,
                                                         506,
                                                               507,
                                                                     508],
                -2,
                 -3.
                       -2,
                                   0.
                                              503,
                                                   504,
                                                         505.
                                                               506,
                                                                     507].
        [-507, -506, -505, -504, -503,
                                                                        4],
        [-508, -507, -506, -505, -504,
                                                                       3],
                                        . . . ,
        [-509, -508, -507, -506, -505, ...,
                                                                        2],
        [-510, -509, -508, -507, -506,
                                              -3,
                                                     -2,
                                                                       1],
                                      . . . .
                                                                        0]])
        [<del>-511</del>, -510, -509, -508, -507,
                                                     -3.
         마지막 토큰을 기준으로 첫 번째 토큰은 511만큼 앞에 있음
                                                             자기 자신과의 거리는 0
```

1-2. Relative Positional Encoding

이제 이 relative position을 _relative_position_bucket에 대입하면 상대적인 거리에 따른 버킷 값을 얻을 수 있다.

기준 토큰과 가까운 거리의 토큰은 각기 다른 버킷 할당

```
tensor([[ 0, 17, 18, 19, 20, ..., 31, 31, 31, 31, 31],
[ 1, 0, 17, 18, 19, ..., 31, 31, 31, 31, 31],
[ 2, 1, 0, 17, 18, ..., 31, 31, 31, 31, 31],
[ 3, 2, 1, 0, 17, ..., 31, 31, 31, 31, 31],
[ 4, 3, 2, 1, 0, ..., 31, 31, 31, 31, 31],
...,

말리떨어진 토큰의 위치정보는 덜 민감하게 반영
[15, 15, 15, 15, 15, ..., 0, 17, 18, 19, 20],
[15, 15, 15, 15, 15, ..., 1, 0, 17, 18, 19],
[15, 15, 15, 15, 15, ..., 2, 1, 0, 17, 18],
[15, 15, 15, 15, 15, ..., 3, 2, 1, 0, 17],
[15, 15, 15, 15, 15, ..., 4, 3, 2, 1, 0]])

Bidirectional에기 때문에 기준 토큰 앞/뒤로 다른 버킷 항당
```

1-2. Relative Positional Encoding

기존 Self-Attetnion Positional Encoding은 사전에 더해짐

$$z_i = \sum_{j=1}^n \alpha_{ij}(x_j W^V)$$

input and output

$$\alpha_{ij} = \frac{\exp e_{ij}}{\sum_{k=1}^{n} \exp e_{ik}}$$

softmax function

$$e_{ij} = \frac{(x_i W^Q)(x_j W^K)^T}{\sqrt{d_z}}$$

attention score

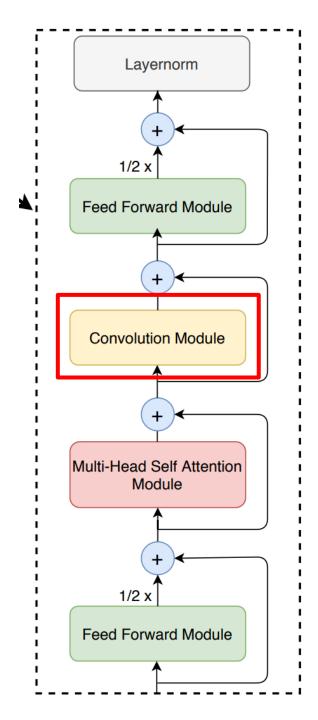
Relative positional encoding은 Attention 계산에 직접 encoding 반영 (a_ij)

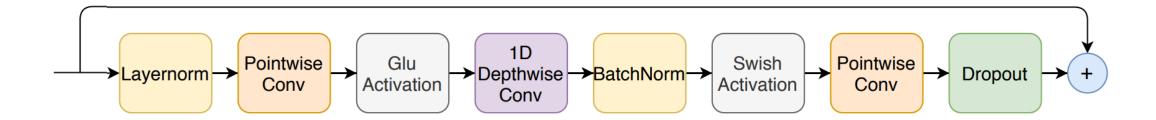
$$z_i = \sum_{j=1}^n \alpha_{ij} (x_j W^V + a_{ij}^V)$$

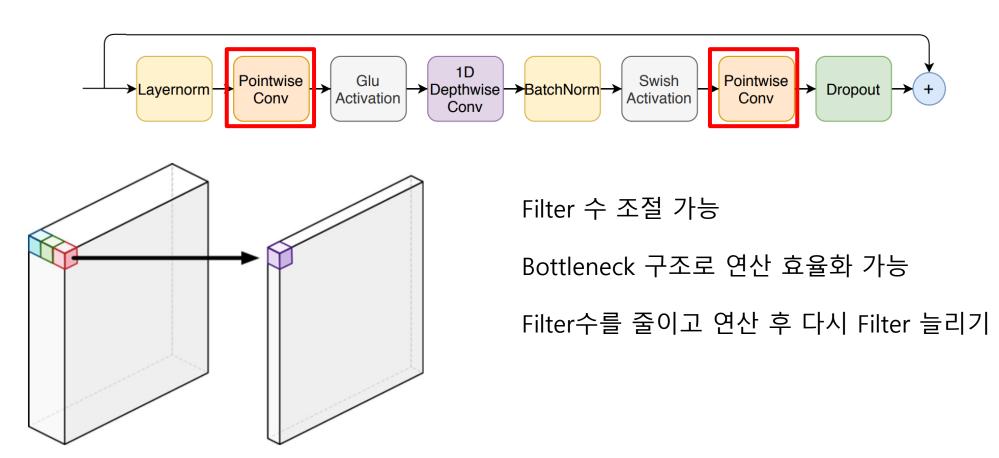
new input and output

$$e_{ij} = \frac{x_i W^Q (x_j W^K + a_{ij}^K)^T}{\sqrt{d_z}}$$

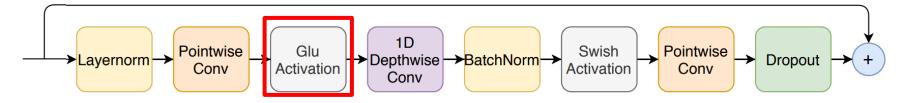
new attention score







2. Convolution Module



Gated Linear Unit

It is used in natural language processing architectures, for example the Gated CNN, because here b is the gate that control what information from a is passed up to the following layer. Intuitively, for a language modeling task, the gating mechanism allows selection of words or features that are important for predicting the next word. The GLU also has non-linear capabilities, but has a linear path for the gradient so diminishes the vanishing gradient problem.

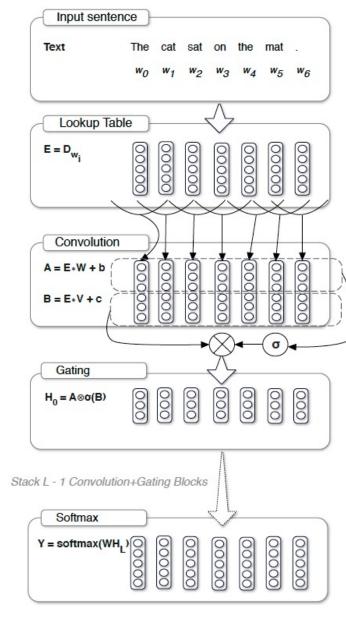
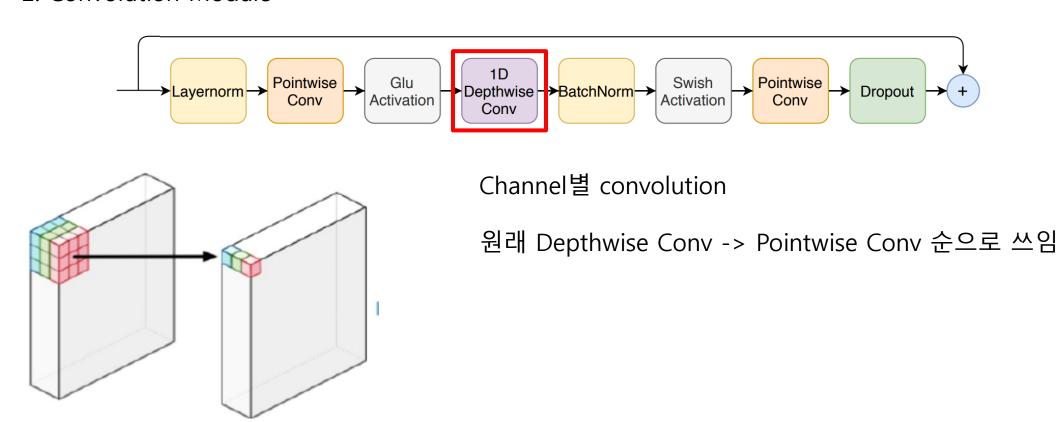
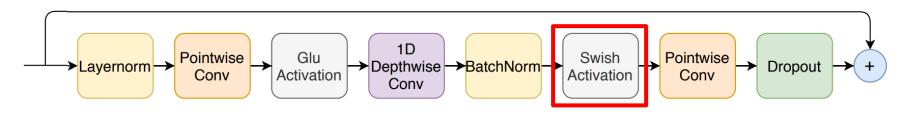


Figure 1. Architecture of the gated convolutional network for language modeling.

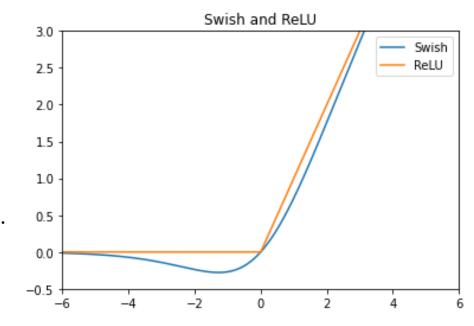


2. Convolution Module

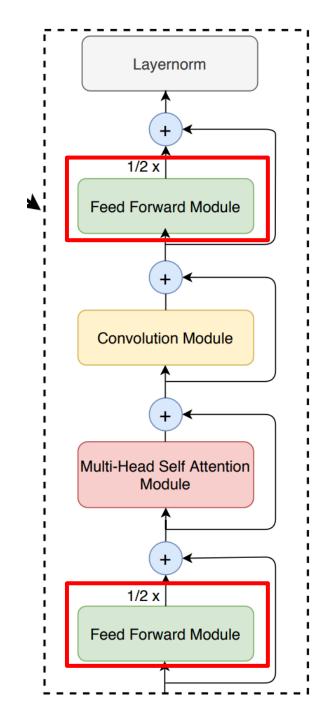


$$f(x) = x \cdot \sigma(x),$$

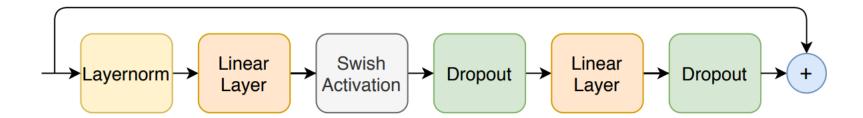
Sigmoid Activation Function에 x를 곱해준 단순한 형태
Sigmoid(B*x)로 B를 학습 가능한 파라미터로 넣기도 한다.
SiLU라고도 불림



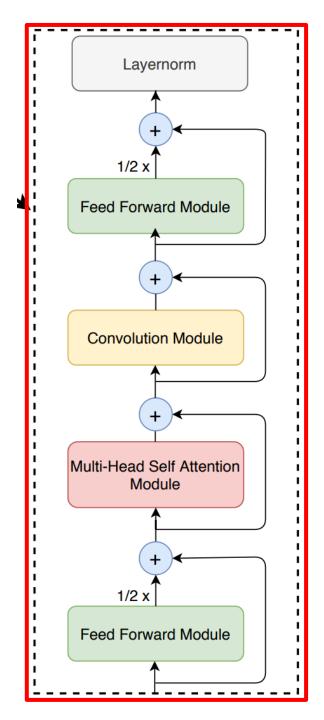
3. FeedForward Module



3. FeedForward Module




4. Encoder Block



4. Encoder Block

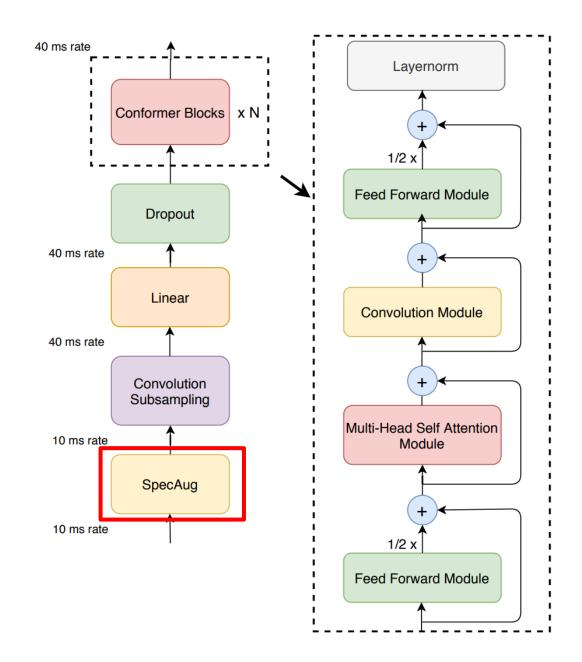
Macaron-Net에서 영감을 받아 sandwich structure를 고안 FFNN을 2-half-step FFNN으로 변경

$$ilde{x_i} = x_i + rac{1}{2} ext{FFN}(x_i)$$
 $x_i' = ilde{x_i} + ext{MHSA}(ilde{x_i})$
 $x_i'' = x_i' + ext{Conv}(x_i')$
 $y_i = ext{Layernorm}(x_i'' + rac{1}{2} ext{FFN}(x_i''))$



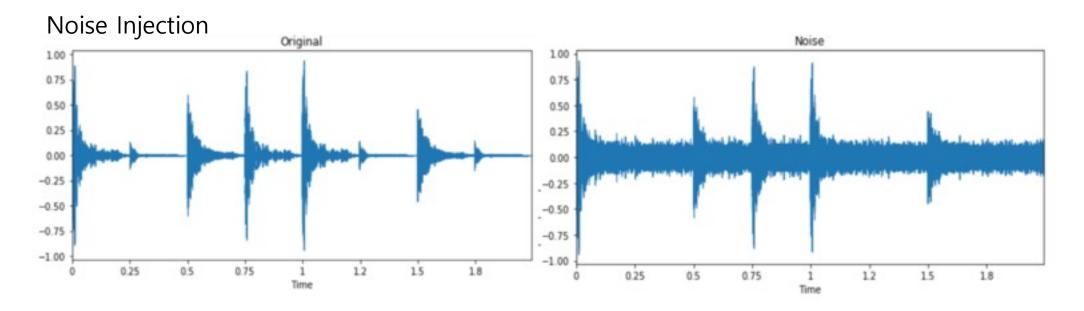


5. SpecAug



5. SpecAugment

기본적인(옛날에 쓰던) Speech Augmentation

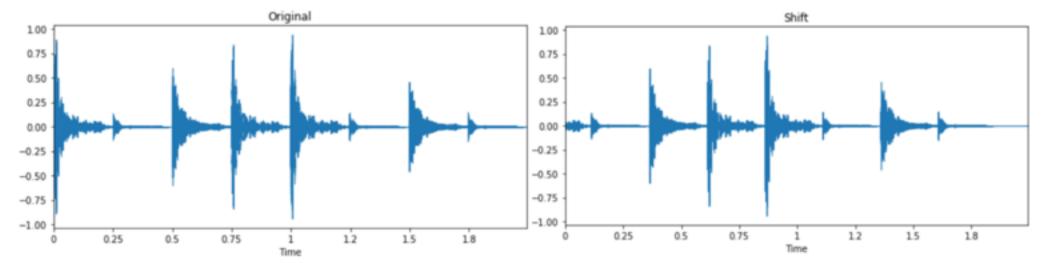


Raw audio에 임의의 난수를 더하여 Noise 추가

5. SpecAugment

기본적인(옛날에 쓰던) Speech Augmentation

Shifting Time

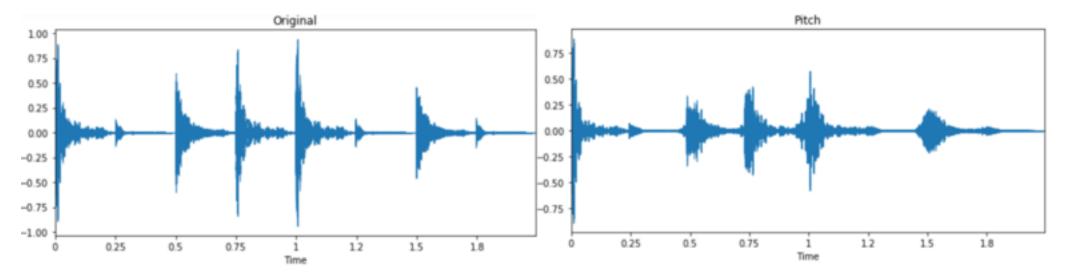


Raw audio를 한 방향으로 밀고 빈 공간 0으로

5. SpecAugment

기본적인(옛날에 쓰던) Speech Augmentation

Changing Pitch

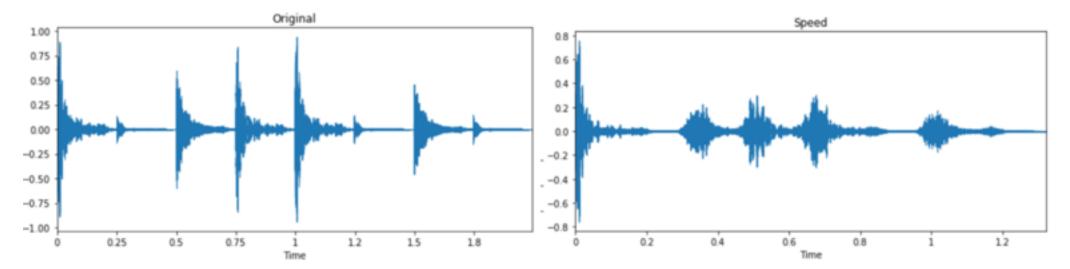


Raw audio의 Pitch(음높이 or 주파수)를 조정

5. SpecAugment

기본적인(옛날에 쓰던) Speech Augmentation

Changing Speed



Raw audio의 속도를 바꿔줌

5. SpecAugment

본 논문에서는 굳이 Raw Audio를 바꿀 필요가 없다고 주장

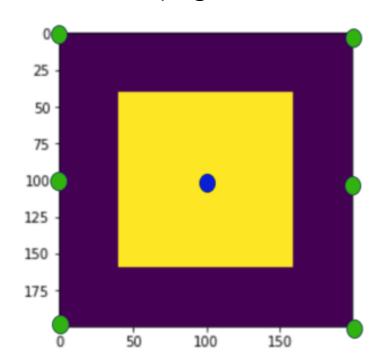
MFCC / Log Mel-spectrogram을 사용하는데, 여기서 augmentation을 하자!

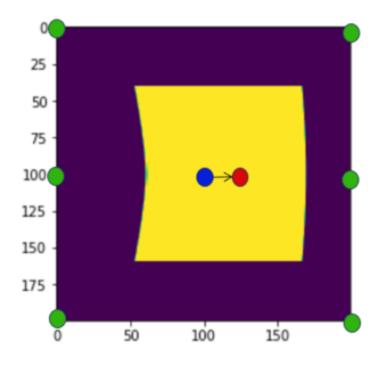
MFCC / Log Mel-spectrogram을 이미지와 비슷하게 생각하고 Augmentation기법 3가지를 제시

위의 방법으로 SOTA달성

5. SpecAugment

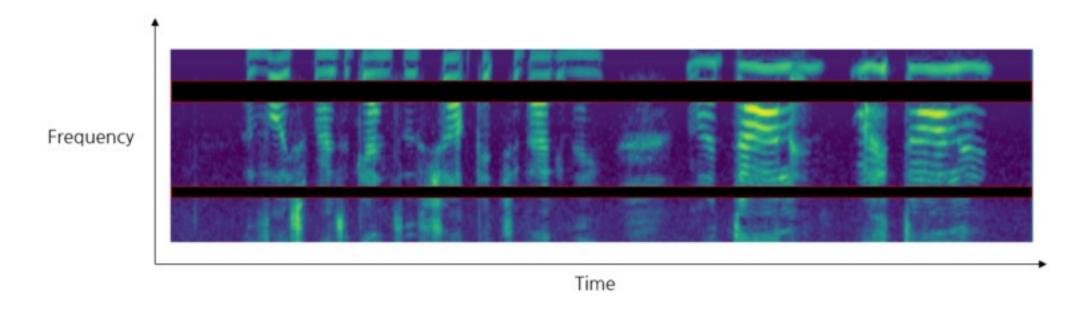
(1) Time Warping





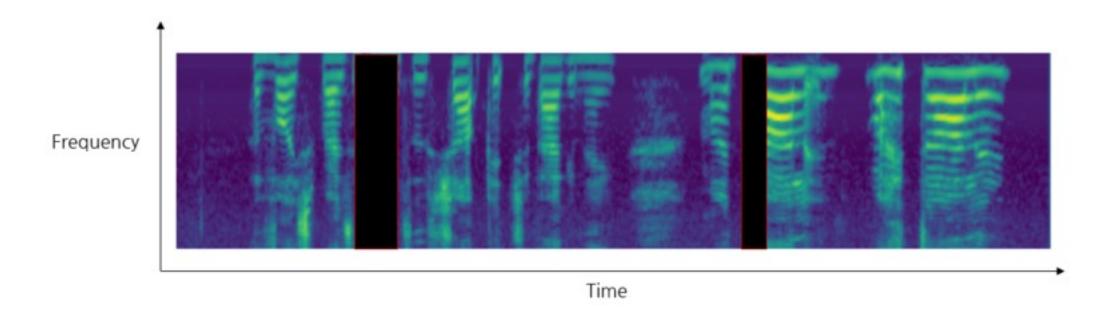
MFCC / log mel-spectrogram 를 이미지처럼 보고 Warping을 수행

- 5. SpecAugment
- (2) Frequency Masking



MFCC / log mel-spectrogram의 Frequency축을 그냥 간단하게 mask해버림

- 5. SpecAugment
- (3) Time Masking



MFCC / log mel-spectrogram의 Time축을 그냥 간단하게 mask해버림

